

Projet d'Apprentissage Supervisé

Mouhamed SAMB Moustapha KEBE
Mouhamadou lamine GNING

Master 2 MLSD/AMSD
Centre Borelli – Université Paris Cité
Année académique 2024/2025

Table des matières

1	Introduction	3
I	Données Crédits bancaires	3
2	Importation et Chargement des Données	3
2.1	Bibliothèques Utilisées	3
2.2	Source des Données	3
3	Analyse Exploratoire des Données	3
3.1	Description du Dataset	3
3.2	Variables du Dataset	3
3.3	Distribution des Classes	4
3.4	Analyse des Variables Numériques	5
4	Préparation des Données	5
4.1	Prétraitement	5
5	Modélisation et Évaluation	6
5.1	Modèles Implémentés	6
5.2	Résultats Comparatifs	7
6	Conclusion de la partie 1	7
II	Données Relationnelles	7
7	Introduction	7
8	Description des Données	8
8.1	Structure des Jeux de Données	8
8.2	Distribution des Classes	8

9	Méthodologie	8
9.1	Prétraitement	8
9.2	Architecture MLP	8
10	Résultats et Analyse	9
10.1	CiteSeer	9
10.2	PubMed	9
10.3	CORA	9
11	Comparaison des Approches	9
11.1	Impact de la PCA	9
12	Conclusion Générale	9

1 Introduction

Ce projet s'inscrit dans le cadre du cours d'apprentissage supervisé du Master 2 MLSD/AMSD. L'objectif est de mettre en pratique différentes techniques d'apprentissage supervisé à travers l'étude de deux types de données réelles : les données de crédits bancaires et les données relationnelles.

Première partie

Données Crédits bancaires

2 Importation et Chargement des Données

2.1 Bibliothèques Utilisées

```
1 import pandas as pd
2 import numpy as np
3 import seaborn as sns
4 import matplotlib.pyplot as plt
5 from sklearn.preprocessing import StandardScaler, LabelEncoder
6 from sklearn.model_selection import train_test_split
7 from sklearn.metrics import accuracy_score, classification_report
8 from imblearn.over_sampling import SMOTE
```

2.2 Source des Données

Les données proviennent du dataset "German Credit Data", accessible via :

```
1 url = "https://raw.githubusercontent.com/jbrownlee/Datasets/
    master/german.csv"
```

3 Analyse Exploratoire des Données

3.1 Description du Dataset

Le jeu de données comprend :

- 1000 exemples de demandes de crédit
- 20 variables dont :
 - 7 variables numériques (entiers)
 - 13 variables catégorielles
- Variable cible binaire (1.1 : bon crédit, 2 : mauvais crédit)

3.2 Variables du Dataset

Les variables comprennent :

- Informations sur le compte courant
- Durée du crédit
- Historique de crédit
- Montant du crédit
- Épargne
- Emploi
- Caractéristiques personnelles (âge, sexe, etc.)
- Autres informations financières

3.3 Distribution des Classes



FIGURE 1 – Distribution des classes de crédit

3.4 Analyse des Variables Numériques




FIGURE 2 – Matrice de corrélation des variables numériques

4 Préparation des Données

4.1 Prétraitement

1. Séparation des features et de la cible
2. Encodage des variables catégorielles
3. Standardisation des features numériques
4. Gestion du déséquilibre des classes avec SMOTE



(a) Distribution avant SMOTE

(b) Distribution après SMOTE

FIGURE 3 – Impact de SMOTE sur la distribution des classes

5 Modélisation et Évaluation

5.1 Modèles Implémentés

- Classifieurs de base :
 - Naive Bayes
 - KNN
- Méthodes discriminantes :
 - LDA
 - QDA
- SVM :
 - Linéaire
 - Noyau RBF
- Méthodes ensemblistes :
 - Random Forest
 - Gradient Boosting
 - AdaBoost

5.2 Résultats Comparatifs




FIGURE 4 – Comparaison des performances des modèles

6 Conclusion de la partie 1

L'analyse approfondie des différents modèles de classification a révélé que le Gradient Boosting offre les meilleures performances pour cette tâche de prédiction de crédit, avec :

- Une accuracy de 0.807 sur l'ensemble de test
- Une bonne stabilité lors de la validation croisée
- Un bon équilibre entre précision (0.76) et rappel (0.88)

Les facteurs clés du succès de cette approche incluent :

- Le prétraitement approprié des données avec standardisation
- La gestion efficace du déséquilibre des classes avec SMOTE
- L'utilisation d'un modèle complexe capable de capturer les relations non linéaires

Deuxième partie

Données Relationnelles

7 Introduction

Cette partie traite de l'analyse de trois bases de données relationnelles majeures utilisées dans la classification de documents scientifiques : Cora, CiteSeer et PubMed. Ces datasets représentent des réseaux de citations avec leurs caractéristiques textuelles respectives.

8 Description des Données

8.1 Structure des Jeux de Données

Les données relationnelles comprennent :

- Une matrice des valeurs objets/caractéristiques
- Un graphe des liens entre objets (matrice d'adjacence)

Dataset	# individus	# liens	# variables	#classes
Cora	2780	5429	1433	7
CiteSeer	3327	4732	3703	6
Pubmed	19717	44338	500	3

TABLE 1 – Caractéristiques des bases de données relationnelles

8.2 Distribution des Classes




FIGURE 5 – Distribution des classes pour chaque dataset

9 Méthodologie

9.1 Prétraitement

Trois approches ont été implémentées :

1. Utilisation exclusive de la matrice X
2. Combinaison des informations W et X : $M=D^{-1}*W*X$
3. Application de techniques d'équilibrage des classes spécifiques à chaque dataset :
 - CiteSeer : SMOTE sampling
 - Pubmed : Undersampling
 - Cora : Oversampling

9.2 Architecture MLP

```
1 def model(X, y):  
2     model = Sequential()  
3     model.add(Dense(units = 128, activation='relu'))  
4     model.add(Dropout(rate=0.2))  
5     model.add(Dense(units = 64, activation='relu'))
```



```

6     model.add(Dropout(rate=0.2))
7     model.add(Dense(units = y.nunique()[0], activation='softmax')
8         )
9     model.compile(optimizer='adam',
10                  loss='sparse_categorical_crossentropy',
11                  metrics=['accuracy'])
12     return model

```

10 Résultats et Analyse

10.1 CiteSeer

- Architecture MLP : Accuracy de 99.37% (après 5 epochs)
- Regression Logistique (avant équilibrage) : 71%
- Naïve Bayes : 74%

10.2 PubMed

- MLP : Accuracy de 99% (5 epochs)
- SVM linéaire : Meilleure performance parmi les méthodes classiques
- Impact positif de la vectorisation TF/IDF

10.3 CORA

- Moyenne de 3.90 voisins par nœud
- Performance MLP : 95.11% après 7 epochs
- SVM et Regression Logistique : ~85-90% d'accuracy

11 Comparaison des Approches

11.1 Impact de la PCA

Les résultats avec réduction de dimension montrent :

- CiteSeer : Baisse des performances (max 33% accuracy)
- CORA : Performances relativement stables (~70%)
- PubMed : Légère amélioration pour certains modèles

12 Conclusion Générale

L'analyse approfondie de ces trois datasets relationnels a permis de mettre en évidence plusieurs points importants :

- L'architecture MLP à trois couches avec régularisation surpasse systématiquement les méthodes traditionnelles

- Les performances obtenues (99% sur CiteSeer et PubMed) démontrent l'efficacité de l'approche neuronale
- L'utilisation des matrices combinées M améliore généralement les résultats
- La réduction de dimension par PCA n'apporte pas d'amélioration significative

La clé du succès réside dans :

- L'équilibrage approprié des classes
- L'utilisation de techniques de régularisation (Dropout)
- La combinaison efficace des informations de structure (W) et de contenu (X)